

# Modelo Predictivo: Voluntariado

# Machine Learning

Estudiante: Henry Alberto Coronado Villca


Versión: 1.0 | Santa Cruz – Bolivia

# Introducción al Proyecto

Este proyecto trata de tomar de partida una necesidad o apoyo a el voluntariado de la pastoral, que es poder predecir sus horas de voluntariado al final del semestre

Se pasa de evaluaciones simples a un diagnóstico predictivo avanzado usando variables como frecuencia y conflictos, generando alertas tempranas para una gestión proactiva.





# Objetivo General

Desarrollar un sistema predictivo basado en Machine Learning para pronosticar las Horas Totales Finales de cada voluntario y emitir un diagnóstico de riesgo (Riesgo, Alerta, Normal) según la meta anual (N).

01

---

## Predicción de Horas

Estimar acumulación final de horas.

02

---

## Diagnóstico de Riesgo

Clasificar en categorías prácticas.



# Etapa 1: Desarrollo y Diagnóstico del Modelo

Construcción, entrenamiento y validación del algoritmo para precisión y usabilidad.

## Preprocesamiento

División: 60% Train / 20% Validation / 20% Test. Escalado con StandardScaler para equidad en variables y evitar data leakage.

## Entrenamiento

Usar SGDRegressor por su interpretabilidad. Métricas: RMSE para error en horas,  $R^2$  para varianza explicada.



# Persistencia en Etapa 1

Serialización con joblib del modelo y escalador para carga en entornos de producción sin reentrenamiento.



## Entrenamiento

Modelo listo para guardar.



## Persistencia

Archivos .pkl para Etapa 2.

# Etapas:

## Operacionalización y Diagnóstico

Aplicación práctica para la Pastoral usando activos persistidos.

### Carga de Activos

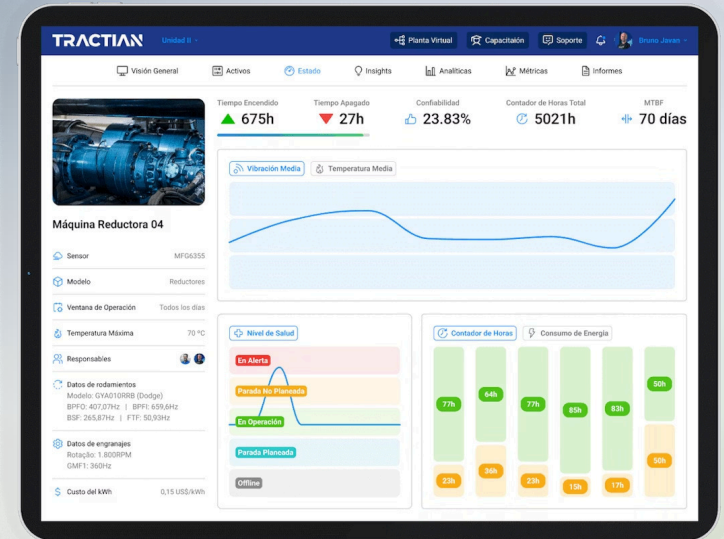
Cargar .pkl y ingresar métricas actuales en DataFrame.

### Preprocesamiento



Transformar datos con escalador persistido para consistencia.

### Predicción

Generar Y-prediction y aplicar reglas: ROJO (<85% N), AMARILLO (N).







# Resultados Obtenidos

7.96

RMSE

Margen de error promedio de  $\pm 8$  horas en predicciones.

0.864

$R^2$

86.40% de variación en horas finales explicada por variables.

# Evidencia del Desarrollo

```
(entVirtual) C:\Users\HenryCoronado\Documents\UCB\Semestre_VI\Machine L\Practices\Proyect>py VoluntaryPredictor_ModelTraining.py
Total de muestras (100%): 1000
Muestras Train (60%): 600
Muestras Validation (20%): 200
Muestras Test (20%): 200

--- Patrón Aprendido (Coeficientes Theta) ---
Peso de X1_Horas_Actuales      : 17.65
Peso de X2_Frec_Semanal        : 5.26
Peso de X3_Horas_Fallidas      : -3.67
Peso de X4_Semanas_Restantes   : 0.00
Peso de X5_Dis_Neta_Restante   : 0.22
Peso de X6_Antigüedad          : 3.08

--- Diagnóstico de Generalización ---
RMSE (Train Set): 7.87 Horas
RMSE (Validation Set): 7.78 Horas
✅ Buena Generalización. Los errores son similares, indicando bajo Overfitting.

--- Evaluación Final (Generalización Real) ---
Error promedio de predicción (RMSE): ±7.96 horas.
Coeficiente de Determinación (R^2): 0.8640
Interpretación: El 86.40% de la variación en las horas finales es explicada por las variables del modelo.

✅ Persistencia exitosa: Modelo y Escalador guardados en 'model_assets/'.

(entVirtual) C:\Users\HenryCoronado\Documents\UCB\Semestre_VI\Machine L\Practices\Proyect>
```

```
(entVirtual) C:\Users\HenryCoronado\Documents\UCB\Semestre_VI\Machine L\Practices\Proyect\entVirtual\Scripts>cd ../..

(entVirtual) C:\Users\HenryCoronado\Documents\UCB\Semestre_VI\Machine L\Practices\Proyect>py VoluntaryPredictor_UseModel.py
Predicción Numérica del Modelo (y_prediccion): 60.2 horas

=====
| Diagnóstico ML para el Voluntario: RIESGO ESTRUCTURAL / ANOMALÍA
| Estado de Riesgo: ROJO
=====
Recomendación para el Voluntario: Alerta inmediata: Se proyecta una falta de 39.8 horas. Debe solicitar un plan de recuperación urgente y priorizar el cumplimiento de X5.
Proyección de Carga para Semestre 2: 39.8 horas a arrastrar.

(entVirtual) C:\Users\HenryCoronado\Documents\UCB\Semestre_VI\Machine L\Practices\Proyect>
```



¡Gracias por  
su atención!